影响 AI 信任 (trust_ai_pct) 的因素：变量分组与特征选择

数据：ai_trust_by_country.csv，47 个国家，36 个候选特征(已排除泄漏变量，见方法页)。本报告中的每个数字和图表，都可以用同目录下的 feature_selection_report.py 从原始 CSV 重新算出；所有中间表格另存在 report_output/*.csv。

核心发现

- 1. 总体上变量之间关系紧密。36 个候选特征两两之间共 630 对，|Spearman ρ| 的中位数为 0.52；53% 的变量对 |ρ|≥0.5，15% 的变量对 |ρ|≥0.75。信息大量重复，不能把它们全部放进模型(图 1)。
- 2. 分组之后，组内变量高度相关。按相关性聚类(数据驱动)得到 15 组，其中 7 组有多个成员，这些组内变量的平均 |ρ| = 0.82(图 2、图 3)。按题目含义手工分的 11 个主题，组内平均 |ρ| = 0.69，随机打乱标签只有 0.47(置换检验 p = 0.0002)。
- 3. 分组之后，组间差距变大。数据驱动分组的组间平均 |ρ| 只有 0.44(组内 0.82)；主题分组的组间为 0.45(组内 0.69)(图 3、图 4)。因此每组只需保留少数代表变量。
- 4. 每组内部的选择：用 4 项检验投票，得票≥3 且在所属聚类中与 trust 的 |ρ| 最大者入选(图 5)。规则选出 3 个：safeguards_sufficient、couldnt_work_without_ai、increased_efficiency；另手工加入 log_gdp 作为经济背景的控制变量，最终 4 个特征。
- 5. 预测表现：4 个特征的交叉验证 R^2 与 36 个特征的全量模型相当甚至更好，且共线性大幅降低(图 7)。注意：特征是用全部 47 行数据选出的，所以该 R^2 偏乐观，见最后一页的局限说明。

本报告页面

图 1 总体相关性 | 图 2 聚类树与重排热图 | 图 3 组内 vs 组间 | 图 4 组间相关矩阵 | 图 5 每组变量对 trust 的影响与选择结果 | 表 1 主题分组的选择 | 图 6 最终特征与 trust 的关系 | 图 7 共线性与预测表现 | 局限说明

方法：如何分组，如何在组内选变量

0. 先剔除的列

identifier 与泄漏类：country(标识符)；iso3(标识符)；accept_ai_pct(与 trust 几乎是同一概念(接受度)，属于泄漏)；risks_outweigh_benefits_pct(对 AI 的总体评价，是 trust 的结果而非原因)；sentiment(按整体态度打的国家标签)；gdp_per_capita_usd(改用 log_gdp(分布偏斜))；population(改用 log_pop(分布极度偏斜))；region(9 个类别对应 47 行，过于稀疏)；economy_type(改用 0/1 变量 economy_advanced)。剩余 36 个候选特征 = 原有 33 个调查指标 + log_gdp、log_pop、economy_advanced。

1. 分组标准(两套，互相对照)

- 数据驱动分组(主分组)：只看数值，不看含义。相似度 = 两变量 Spearman 秩相关的绝对值 |ρ|，距离 = 1 − |ρ|；用平均连接(average linkage)层次聚类，在距离 0.25 处切树。因为平均连接看的是簇内平均距离，所以“组内平均 |ρ| 约≥0.75”，并不要求每一对都超过该值。0.25 是我设定的经验阈值，可在脚本里改 CUT_DISTANCE。
- 含义分组(对照)：我根据每个调查题目的含义手工分为 11 个主题(如“AI 素养与培训”“组织采用”)，不使用任何数据。用它来检验：数据驱动的分组，是否与“意思相近的题目”一致；以及组内相关性高，不是聚类算法自己造出来的。

2. 组内选变量的方法：四项检验投票 + 每个聚类只留一个

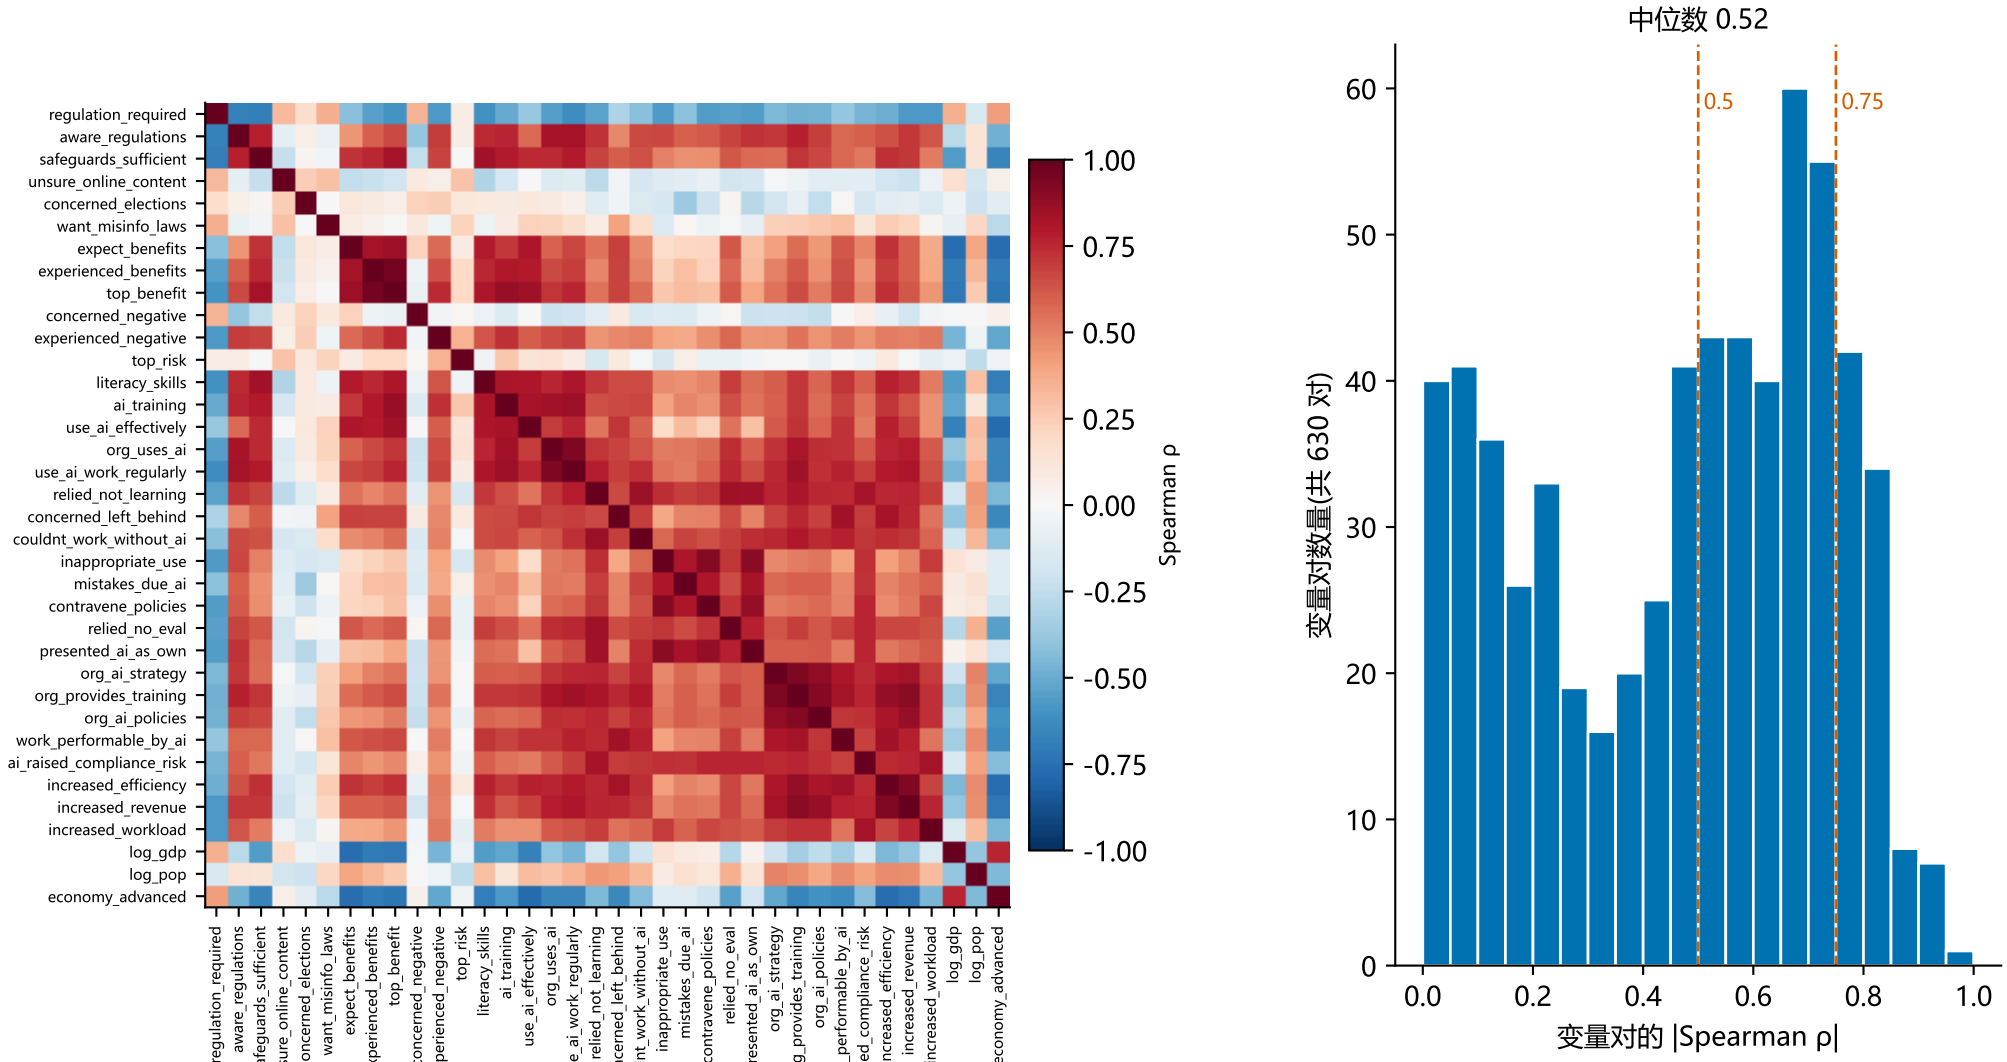
- 检验 1 单变量相关：|Spearman ρ| ≥ 0.5 且 $p < 0.01$。
- 检验 2 互信息(3 近邻估计)：不低于 36 个候选特征的中位数，能捕捉非线性关系。
- 检验 3 Lasso 稳定性：对样本做 200 次自助重采样，每次用 5 折交叉验证的 LassoCV 拟合，系数非零的频率 ≥ 50%。
- 检验 4 随机森林置换重要性：5 折×4 次重复，在留出折上打乱该变量，看预测误差增加多少；取平均后排在前 25%。
- 选择规则：得票≥3(共 4 票)，并且在所属聚类中与 trust 的 |ρ| 最大。这样每个聚类最多入选一个，避免把信息重复的变量同时放进模型。未通过的聚类不入选。
- 人工决定：log_gdp 未通过投票(票数 2)，但因为经济发展水平是关键背景，作为控制变量保留；economy_advanced 与它高度共线，所以只留连续的 log_gdp。

3. 需要注意的点

· 聚类是按相关性分的，所以“组内相关性高”在数据驱动分组里部分是构造出来的；真正独立的证据是含义分组的置换检验(图 3 右)。
· 选择规则与阈值(0.5、中位数、50%、前 25%、3 票)都是经验值，改动会改变名单；safeguards_sufficient 与 couldnt_work_without_ai 在各种设置下都很稳，increased_efficiency 相对不稳。
· 国家层面 47 个样本，结论是预测性的，不代表因果，也不能推到个人层面。

图 1 总体上，候选变量之间关系紧密

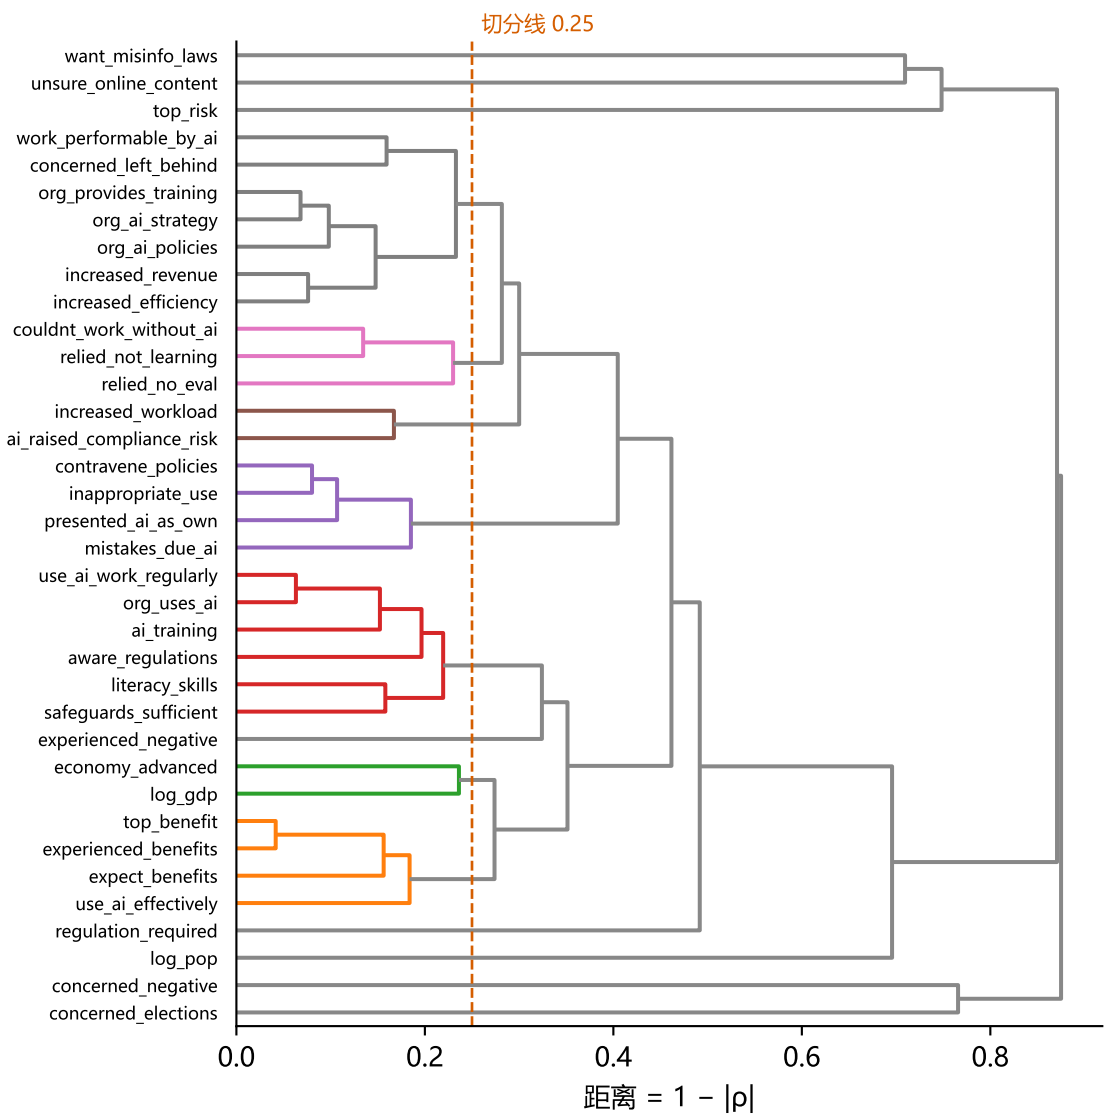
36 个候选特征两两 Spearman 相关(原始列顺序)

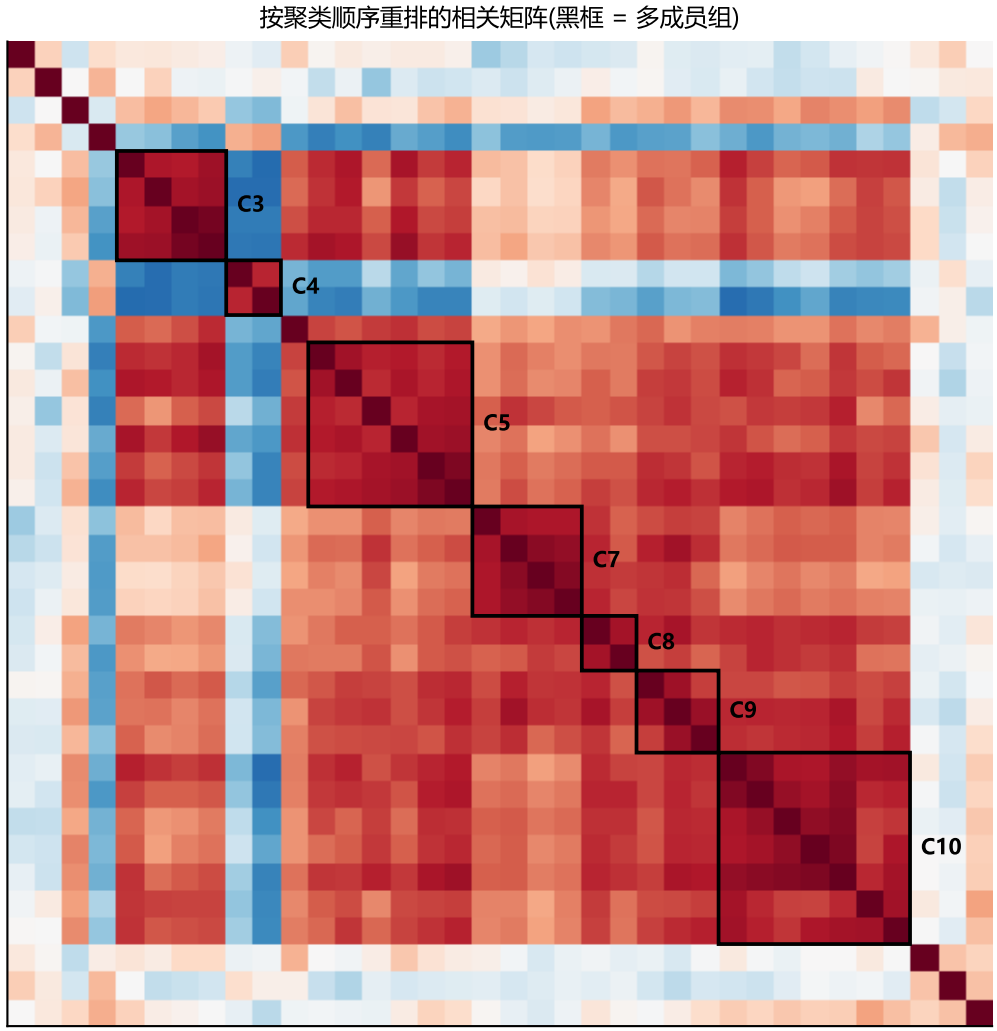


左：36×36 的相关矩阵，红色为正相关、蓝色为负相关，大片深红说明多数变量朝同一方向变化。右：把 630 个变量对的 |ρ| 画成直方图：53% 的变量对 |ρ|≥0.5，15% 的 |ρ|≥0.75，只有 31% 低于 0.3。这意味着许多变量测的是同一件事(各国 AI 采用成熟度)，直接全部放进模型会出现严重共线性，需要先分组去冗余。少数变量(如 concerned_elections、want_misinfo_laws、log_pop)与其他变量相关性弱，位于图中的浅色带。

图 2 按相关性聚类后，出现清晰的“块”

距离 = 1 − |ρ|，平均连接，在 0.25 处切分 → 15 组

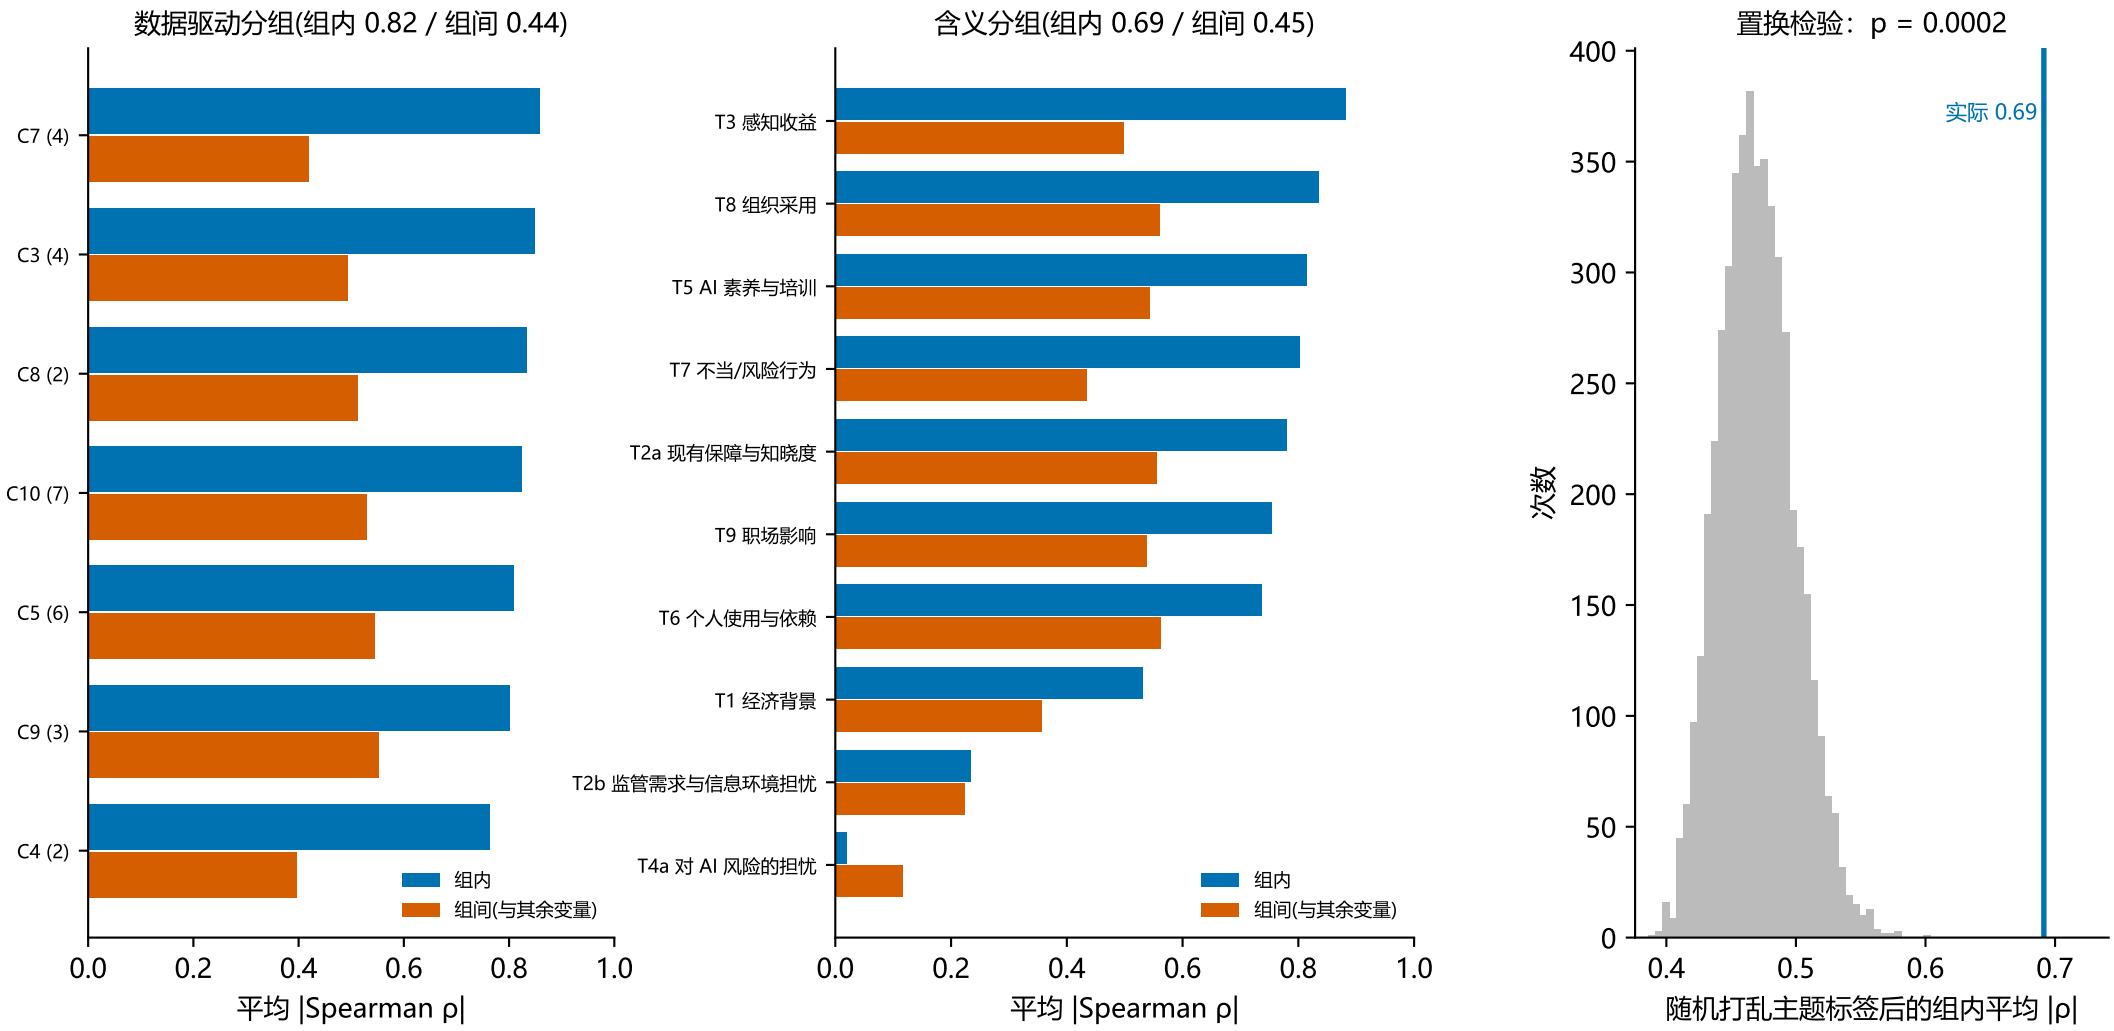




左：树状图，两个变量在越靠左的位置合并，说明越相似；橙色虚线为切分线，线以左连在一起的变量归为一组。右：用同一顺序重排相关矩阵后，相似变量聚在对角线上形成深红色的块，黑框标出 7 个多成员组(方括号内为成员数：C3[4] C4[2] C5[6] C7[4] C8[2] C9[3] C10[7])。其余 8 个变量与别的变量都不够相似，各自单独成组。组的编号 C* 沿用脚本里 fcluster 的输出，成员名单见 report_output/11_group_assignments.csv。

图 3 分组之后：组内相关性高，组间相关性低

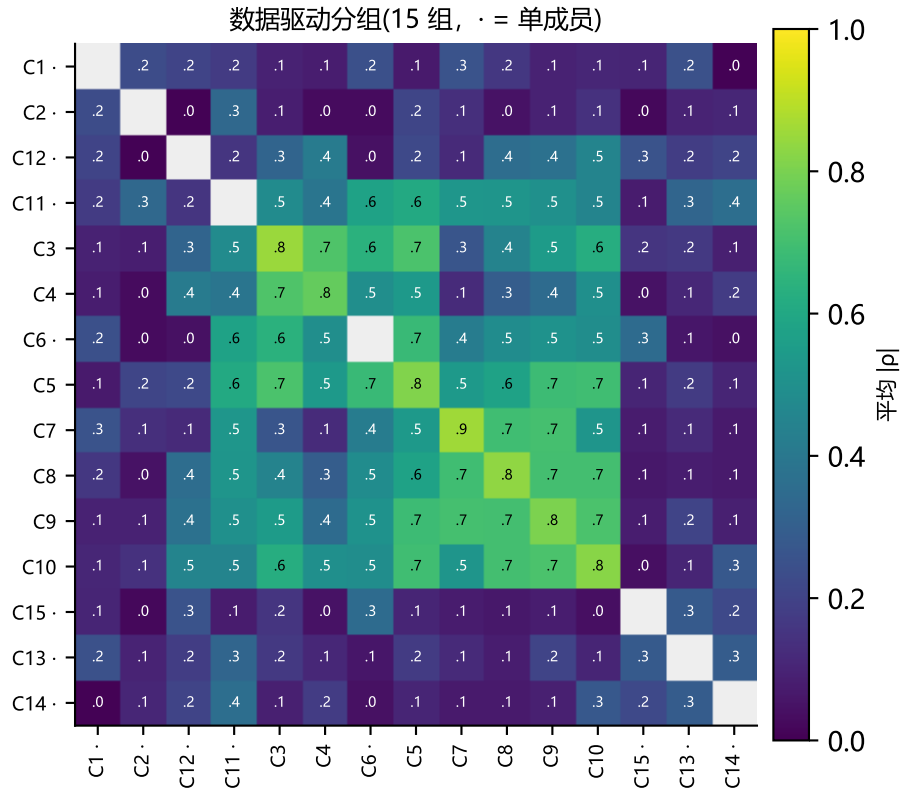
每个多成员组的组内平均 |ρ|(蓝) vs 该组与其余所有变量的平均 |ρ|(橙)

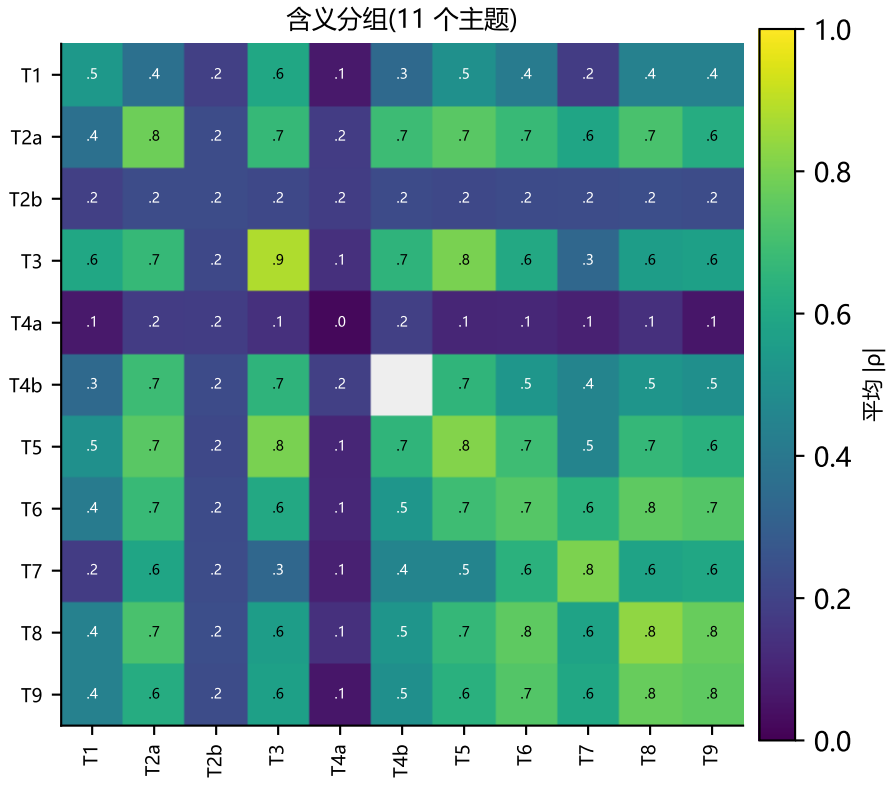


左：数据驱动分组中，全部 7 个多成员组的组内相关(蓝)高于组间(橙)。这部分有“构造”成分——聚类本来就是把相关性高的放在一起。中：更有说服力的是按含义分的主题，它没有用到数据，但组内平均 |ρ| 仍是 0.69，高于组间的 0.45。右：把 36 个变量随机分到相同大小的组里重复 5000 次，组内均值只有 0.47 左右，实际值 0.69 远高于随机水平 (p = 0.0002)，说明“意思相近的题目，数据上也相近”。例外：T2b 监管需求与信息环境担忧、T4a 对 AI 风险的担忧 的组内相关很弱，说明这些题目虽然主题相近，但测的其实是不同的东西。

图 4 组间差距：对角线(组内)明显亮于非对角线(组间)

单元格 = 两组成员之间的平均 |ρ|；对角线 = 组内平均 |ρ|(单成员组为空)



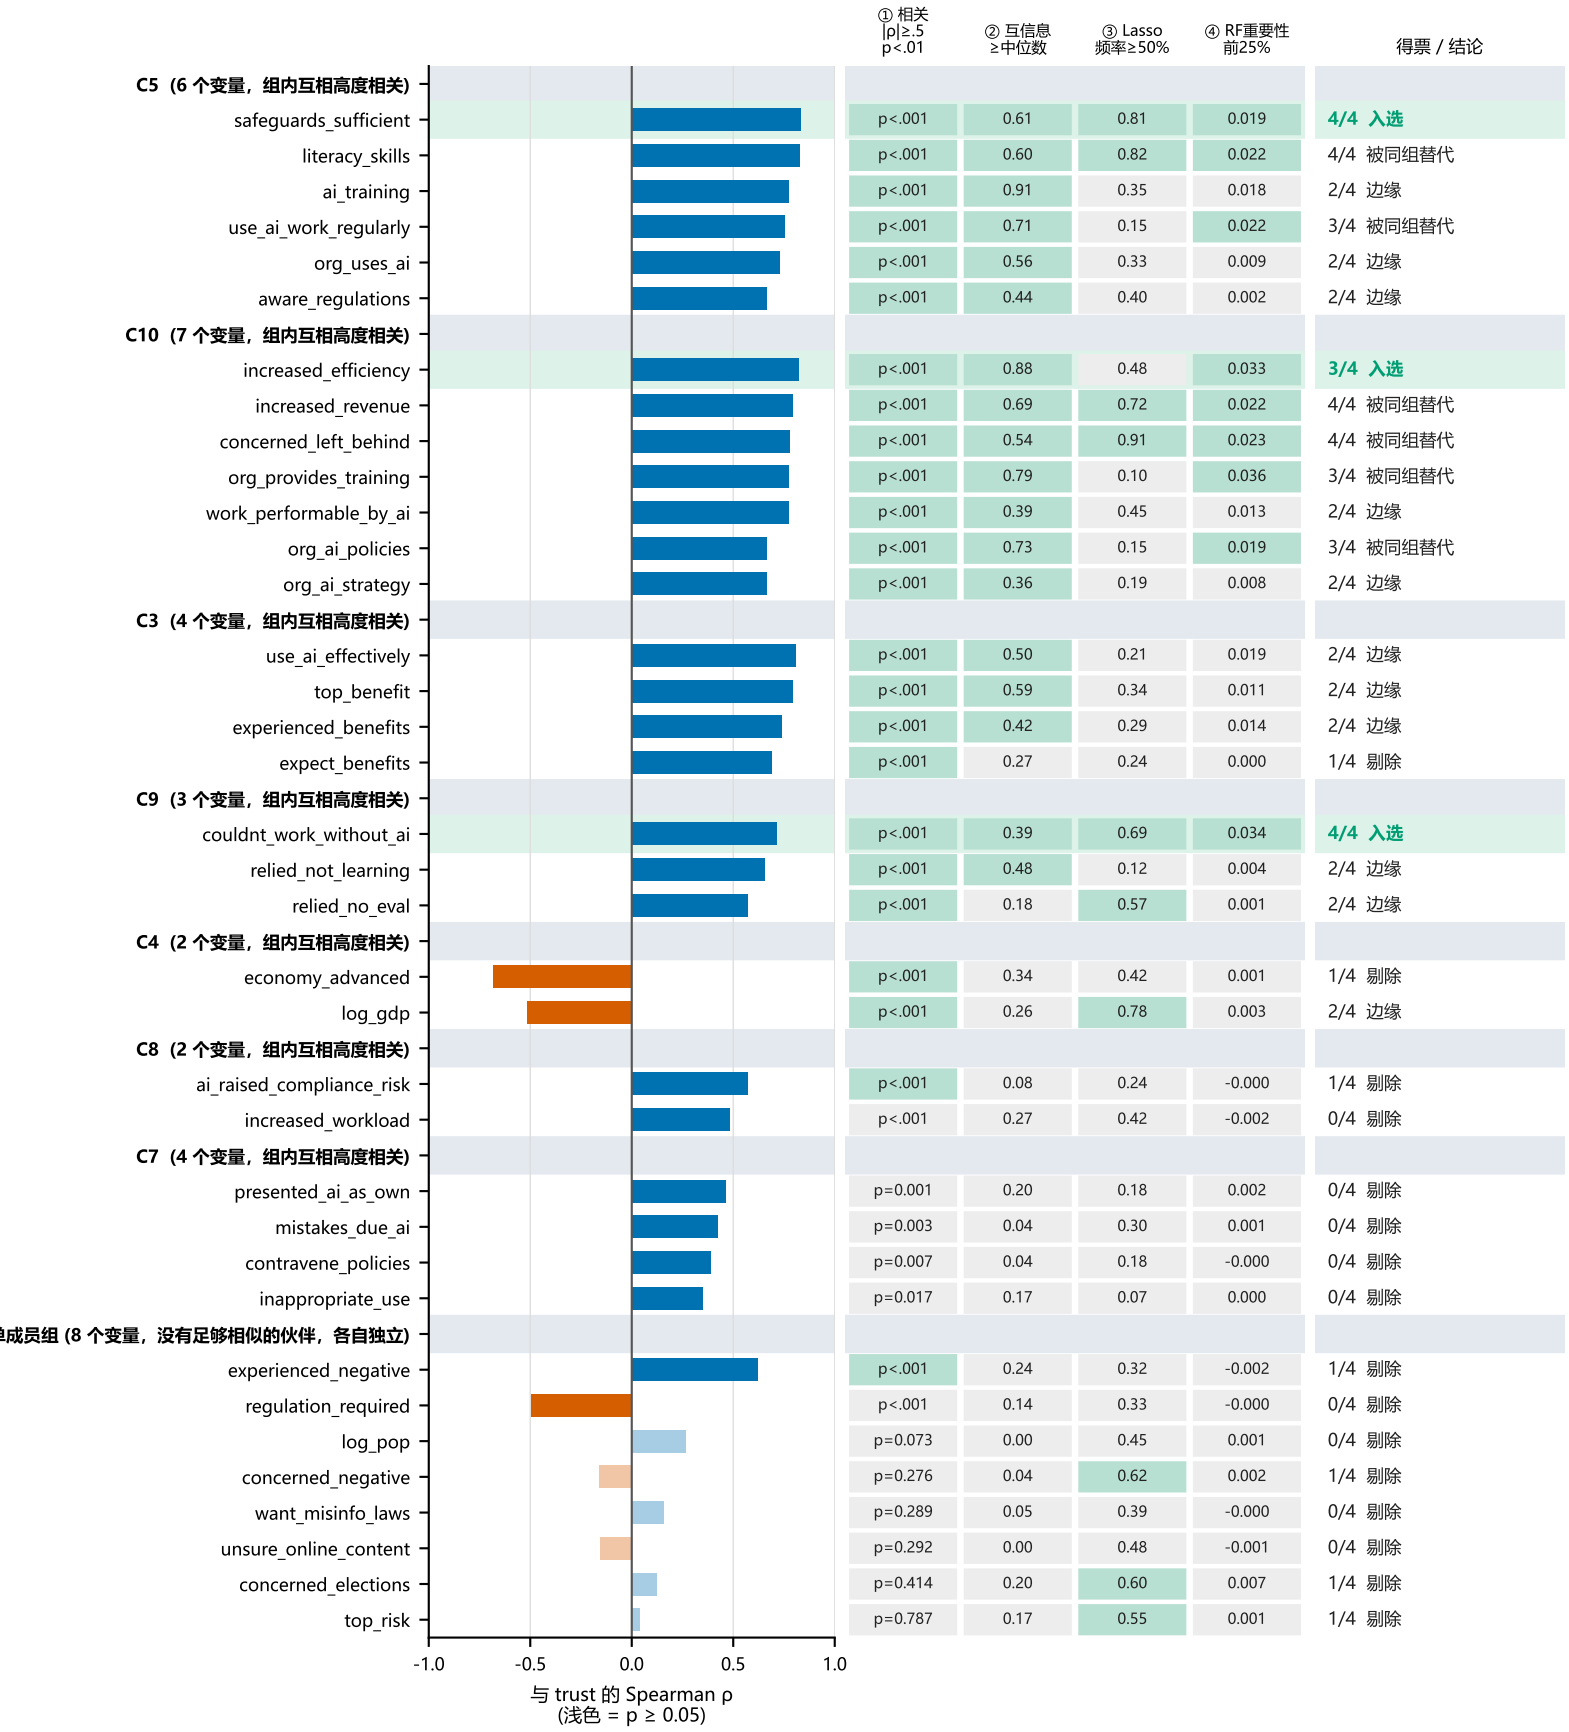


每个格子是“行组”与“列组”成员之间所有变量对的平均 |ρ|，数字省略了小数点前的 0(.8 表示 0.8)。数据驱动分组：对角线(组内)各组均值 0.82，非对角线(组间)均值 0.29。含义分组：对角线 0.64，非对角线 0.44(这里是各组简单平均，与图 3 的“全部变量对合并平均”略有差异)。注意：组间并非无关——例如“AI 素养”“组织采用”“职场影响”之间的组间相关仍然较高，这些变量共同反映各国 AI 采用成熟度；而“监管需求”“风险担忧”等主题与其余主题的相关较低。所以每个大类里保留一个代表，而不是每个聚类之间都彼此独立

。

图 5 每个组内的变量对 trust 的影响，以及选择结果

条形 = 与 trust 的 Spearman ρ；绿格 = 通过该项检验；绿色底纹 = 最终入选



读法：每组是一簇互相高度相关的变量(灰色标题行)。组内各变量与 trust 的相关方向一致、强度接近，因此只需选一个：得票≥3 且 |ρ| 最大者入选(绿底)。“被同组替代”表示通过了检验，但同组有 |ρ| 更高的变量。与 trust 呈负相关的只有 regulation_required、unsure_online_content、concerned_negative、log_gdp、economy_advanced(经济越发达、越强调监管，信任越低)，其余变量都是正相关。注意 safeguards_sufficient 等变量与 trust 的高相关，未必意味着因果。

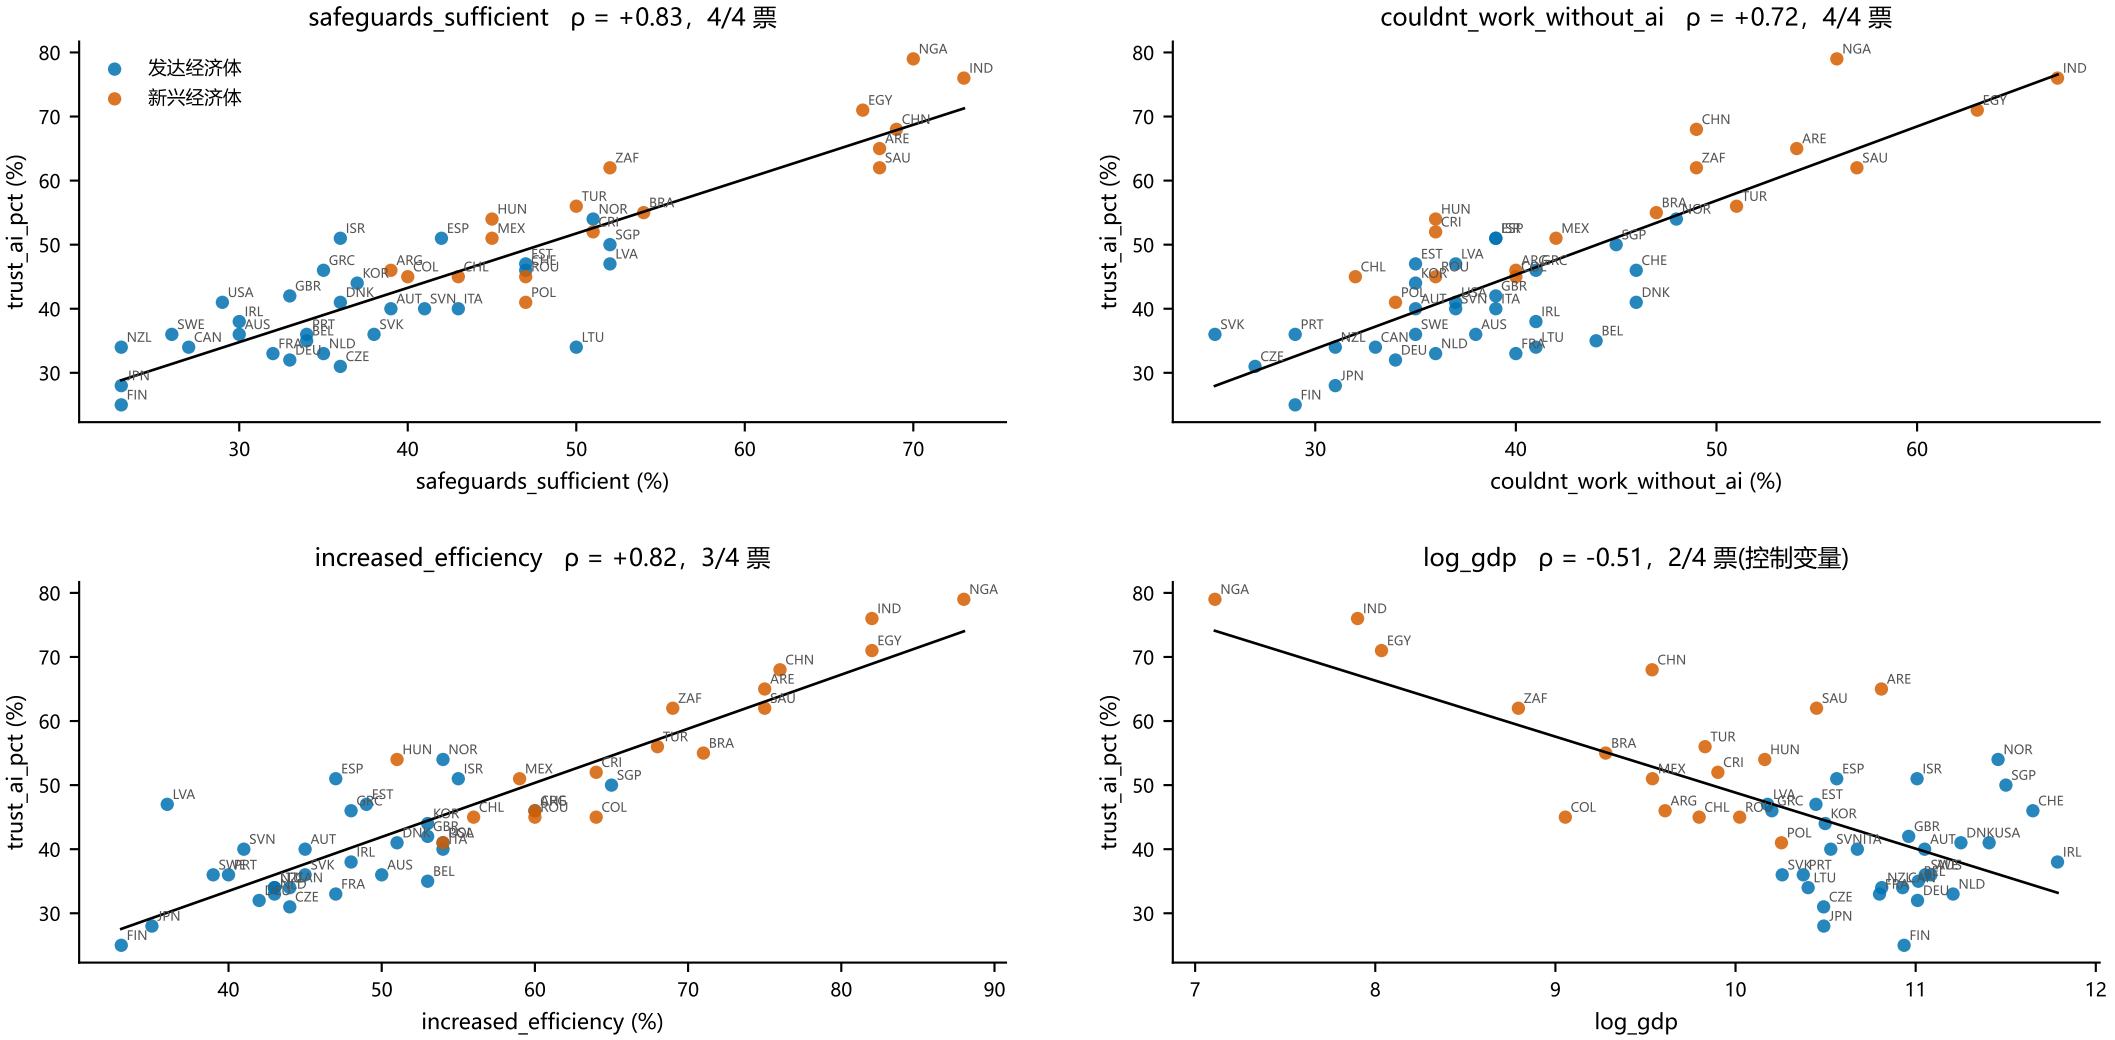
表 1 含义分组：每个主题的代表变量(同样规则：票数最多，并列取 |ρ| 最大)

主题	成员数	组内平均|ρ|	代表变量	与 trust 的 ρ	得票	是否入选
T1 经济背景	3	0.53	log_gdp	-0.51	2/4	未通过
T2a 现有保障与知晓度	2	0.78	safeguards_sufficient	+0.83	4/4	通过(≥3 票)
T2b 监管需求与信息环境担忧	4	0.23	concerned_elections	+0.12	1/4	未通过
T3 感知收益	3	0.88	top_benefit	+0.79	2/4	未通过
T4a 对 AI 风险的担忧	2	0.02	concerned_negative	-0.16	1/4	未通过
T4b 实际遭遇负面结果	1	-	experienced_negative	+0.62	1/4	未通过
T5 AI 素养与培训	3	0.82	literacy_skills	+0.83	4/4	通过(≥3 票)
T6 个人使用与依赖	4	0.74	concerned_left_behind	+0.78	4/4	通过(≥3 票)
T7 不当/风险行为	5	0.80	relied_no_eval	+0.57	2/4	未通过
T8 组织采用	4	0.83	org_provides_training	+0.78	3/4	通过(≥3 票)
T9 职场影响	5	0.75	increased_revenue	+0.79	4/4	通过(≥3 票)

两套分组选出的变量对比：数据驱动 → safeguards_sufficient、couldnt_work_without_ai、increased_efficiency、log_gdp；含义分组 → safeguards_sufficient、literacy_skills、concerned_left_behind、org_provides_training、increased_revenue(另加 log_gdp)。含义分组的代表更多，因为它把强相关但含义不同的变量(如培训、素养、收益)分在不同主题里；但它选出的 org_provides_training 与 increased_revenue 相关系数高达 0.90，放进同一个线性模型会共线。 “T2b” “T4a”这类组内平均 |ρ| 很低的主题，说明分组本身就不成立(题目含义相近，但数据上无关)，它们没有变量通过检验，也符合预期。

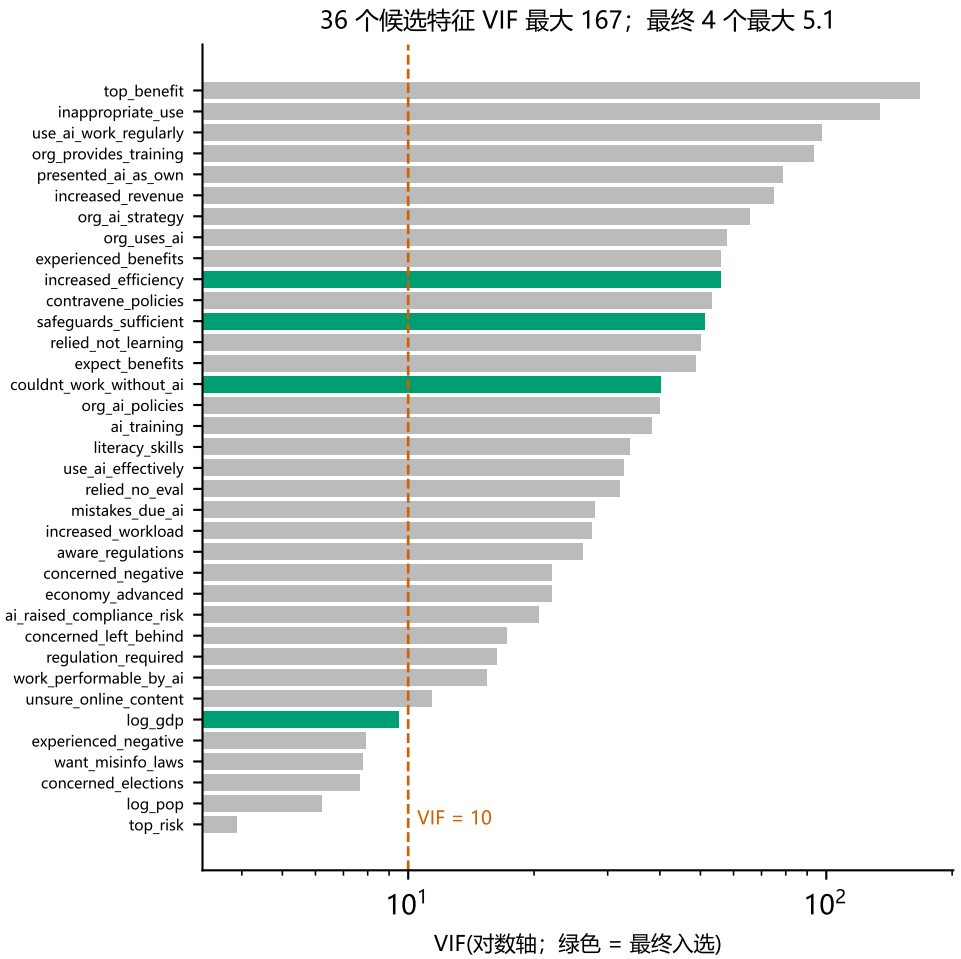
图 6 最终入选的特征与 trust 的关系

最终 4 个：safeguards_sufficient、couldnt_work_without_ai、increased_efficiency、log_gdp



每个点是一个国家，蓝 = 发达经济体、橙 = 新兴经济体，黑线为最小二乘拟合线。前三个变量与 trust 都是清晰的正向关系；log_gdp 是负相关(人均 GDP 越高，信任越低)，且新兴/发达经济体在图上明显分成两簇，这也是要把它作为控制变量保留的原因。入选变量之间的 |ρ| 在 0.20–0.74，共线性可控(最大 VIF = 5.1，见下页)。这些是国家层面的相关关系，不能解释为因果。

图 7 选择的效果：共线性大幅降低，预测能力没有明显损失



方案	特征数	CV R^2(均值±SD)	RMSE	备注
基线：预测均值	0	-0.28 ± 0.71	12.4	-
全部 36 个特征 - Ridge	36	0.67 ± 0.32	5.6	无偏
全部 36 个特征 - Lasso	36	0.71 ± 0.28	5.2	无偏
折内选 4 个(SelectKBest) - Ridge	36	0.73 ± 0.26	5.0	无偏(选择在每折内完成)
最终 4 个特征 - Ridge	4	0.78 ± 0.22	4.4	偏乐观(用全部数据选特征)
最终 4 个特征 - 随机森林	4	0.71 ± 0.29	5.3	偏乐观(用全部数据选特征)

左：VIF 衡量一个变量能被其他变量线性解释的程度，>10 通常认为共线性严重。36 个候选特征中有 30 个超过 10；分组选择后只剩 4 个，最大 VIF 为 5.1。右：重复 5 折交叉验证(10 次重复)。最终 4 个特征的 R^2 与 36 个特征的全量模型相当，甚至更高；“折内选择”一行把选特征放进每一折里完成，是最无偏的基准。标为“偏乐观”的两行，其特征是用全部 47 行选出来的，测试折的信息已经参与了选择，实际泛化表现应更接近“折内选择”一行。R^2 的标准差较大(每折只有约 9 个国家)，方案之间的小差异不应过度解读。

局限与需要你判断的地方

- 特征是用全部 47 行选出的，随后评估用的还是这批数据，所以“最终特征”的 CV R^2 偏乐观；无偏的对照是“折内选择”。如果之后要做 70/30 的训练/测试划分，严格做法应只用训练集做特征选择。
- 样本只有 47 个国家，而候选特征有 36 个。相关系数、Lasso 频率、重要性排名都有较大不确定性，阈值稍微变化，名单就可能变化(建议改脚本顶部的参数看敏感性)。
- 数据驱动分组的“组内高相关”部分是聚类造成的；含义分组的置换检验才是独立证据。含义分组由我根据题目文字手工划分，你可以在脚本的 THEMES 字典里修改，所有数字会随之重算。
- 分组之间也不是独立的：AI 素养、组织采用、职场影响、个人使用等很可能都受同一个潜在因素(各国 AI 采用成熟度)驱动，入选变量“预测”了 trust，不等于它“导致”了 trust。
- 不当使用类变量(mistakes_due_ai、inappropriate_use 等)与 trust 正相关，很可能是“使用越多，出现问题的比例越高”的暴露效应，不宜解读成“犯错让人更信任”。
- 人工决定共有三处：剔除泄漏变量(accept_ai_pct 等)；聚类阈值 0.25；保留 log_gdp 作为控制变量。它们都在脚本顶部或注释中标明。

复现方式

```
python feature_selection_report.py # Chinese
python feature_selection_report.py --lang en # English
```

输出 report_output/feature_selection_report.pdf，以及 01~11 号 csv：01 相关矩阵；02/03 组内与组间相关；04 汇总；05 特征表(全部检验结果)；06 主题代表；07 VIF；08 交叉验证表现；09/10 组间矩阵；11 分组名单。设置环境变量 REPORT_PNG=1 还会把每页另存为 PNG。